

```
In [2]: import warnings
warnings.filterwarnings('ignore')
```

Текущая задача - проанализировать имеющиеся данные об ивентах SkyCinema. Надо почистить данные, обсудить, а так же произвести анализ результатов введения новой рекомендательной системы.

Работаем пока с "event_list.xlsx". Сперва изучим датасет на наличие ошибок.

Описание данных

- account_id - идентификатор пользователя
- server_time - время совершения действия
- action_id - идентификатор (тег) действия
- device_type - тип устройства
- user_browser - браузер
- screen_type - тип страницы, на которой совершается действие.

В рамках этого анализа возьмем только те строки, у которых в столбце screen_type значение "player".

Описание ивентов

- 'screenview' - заход на страницу с проигрывателем тайтла
- 'click' - клик по плееру
- 'playback_start' - включение проигрывателя
- 'playback_pause' - постановка проигрывателя на паузу
- 'playback_unpause' - снятия проигрывателя с паузы
- 'playback_stop' - выключение страницы с проигрывателем

```
In [3]: # Выведем датасет
import pandas as pd
df = pd.read_excel('event_list.xlsx')
df
```

Out[3]:

	account_id	server_time	screen_type	action_id	device_type	user_browser
0	102301	2021-10-01 06:58:16	main	screenview	mobile_web	Mobile Safari
1	102301	2021-10-01 06:58:30	main	screenview	mobile_web	Mobile Safari
2	102313	2021-10-01 03:40:19	main	screenview	mobile_web	Chrome
3	102313	2021-10-01 06:51:14	main	screenview	desktop_web	Chrome
4	102313	2021-10-01 06:51:17	main	click	desktop_web	Chrome
...	...	...	...	...	...	...
9995	103823	2021-10-01 21:16:25	player	playback_pause	desktop_web	Chrome
9996	103823	2021-10-01 21:16:31	player	playback_unpause	desktop_web	Chrome
9997	103823	2021-10-01 21:29:16	player	click	desktop_web	Chrome
9998	103823	2021-10-01 21:29:18	player	playback_pause	desktop_web	Chrome
9999	103823	2021-10-01 21:29:30	player	playback_unpause	desktop_web	Chrome

10000 rows × 6 columns



```
In [4]: # Оставим только player и взглянем на общую картину
df = df[df["screen_type"] == 'player']

df.info()
df.head()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 7475 entries, 33 to 9999
Data columns (total 6 columns):
#   Column          Non-Null Count  Dtype
---  -
0   account_id      7475 non-null   int64
1   server_time     7475 non-null   datetime64[ns]
2   screen_type     7475 non-null   object
3   action_id       7475 non-null   object
4   device_type     7475 non-null   object
5   user_browser    7475 non-null   object
dtypes: datetime64[ns](1), int64(1), object(4)
memory usage: 408.8+ KB
```

Out[4]:

	account_id	server_time	screen_type	action_id	device_type	user_browser
33	102313	2021-10-01 09:24:12	player	playback_start	desktop_web	Chrome
34	102313	2021-10-01 09:24:13	player	playback_pause	desktop_web	Chrome
43	102313	2021-10-01 11:53:54	player	playback_start	desktop_web	Chrome
44	102313	2021-10-01 11:53:56	player	playback_pause	desktop_web	Chrome
45	102313	2021-10-01 11:53:56	player	click	desktop_web	Chrome

Задача 1 (активность)

Выделим 10 самых активных пользователей.

Каким браузером чаще всего пользовались эти 10 пользователей?

Какое действие занимает наибольший процент среди всех действий этих 10 пользователей?

In [5]:

```
leaders = df.groupby('account_id')[['action_id']].count().sort_values('action_id')
leaders ### Список самых активных пользователей получен
```

Out[5]:

	account_id
0	102598
1	103398
2	102605
3	102904
4	103149
5	103219
6	103804
7	102405
8	102883
9	103364

In [6]:

```
### Создадим таблицу с группировкой по двум колонкам (пользователи и браузеры) и
df_browsers = df[df['account_id'].isin(leaders['account_id'])].groupby(['account_id', 'user_browser']).count().rename(columns = {'user_browser': 'user_browser', 'action_id': 'cnt_brow_uses'}).reset_index().sort_values('cnt_brow_uses', ascending=False)

### Сгруппируем снова по браузерам и получим топ самых используемых
df_browsers.groupby('user_browser')[['cnt_brow_uses']].sum().reset_index().sort_
```

Out[6]:

	user_browser	cnt_brow_uses
4	Yandex	1004
0	Chrome	968
2	Safari	301
3	Samsung Browser	141
1	Edge	128

Самым используемым браузером оказался "Яндекс".

```
In [7]: df_actions = df[df['account_id'].isin(leaders['account_id'])].groupby('action_id')\
        .rename(columns = {\
        df_actions
```

Out[7]:

	action_id	cnt_action
0	click	1595
1	playback_pause	334
4	playback_unpause	313
2	playback_start	181
3	playback_stop	119

```
In [8]: part = 1595/sum(df_actions['cnt_action'])\
part
```

Out[8]: 0.6274586939417781

Самым частым действием является "Клик" (62.75% от всех действий)

Задача 2 (состоятельность)

Проверим данные на состоятельность:

1. Есть ли клиенты, которые снимали видео с паузы хотя бы раз, но при этом не ставили видео на паузу ни разу?
2. Есть ли клиенты, которые ставили видео на паузу хотя бы раз, но при этом не включали проигрыватель?

С каких устройств и браузеров заходят пользователи, у которых встречаются подобные аномалии?

```
In [9]: def grab_unique (str):\
\
    return df[df['action_id'] == str]['account_id'].unique()

lst_pause = grab_unique('playback_pause')
lst_unpause = grab_unique('playback_unpause')
```

```

lst_start = grab_unique('playback_start')

#print("Список уникальных пользователей действия 'playback_pause':", "\n", lst_pa
#print("Список уникальных пользователей действия 'playback_unpause':", "\n", lst_
#print("Список уникальных пользователей действия 'playback_start':", "\n", lst_st

er_u1 = []
for i in lst_unpause:
    if i not in lst_pause:
        er_u1.append(int(i))

er_u2 = []
for i in lst_pause:
    if i not in lst_start:
        er_u2.append(int(i))

print("Клиенты, которые снимали видео с паузы хотя бы раз, но при этом не ставил
print("Клиенты, которые ставили видео на паузу хотя бы раз, но при этом не включ
print()
print(df[df['account_id'].isin(er_u1)].groupby(['device_type', 'user_browser'])[[
print()
print(df[df['account_id'].isin(er_u2)].groupby(['device_type', 'user_browser'])[[

```

Клиенты, которые снимали видео с паузы хотя бы раз, но при этом не ставили видео на паузу ни разу [102345, 102918, 103050]
 Клиенты, которые ставили видео на паузу хотя бы раз, но при этом не включали проигрыватель [102669, 103052]

	device_type	user_browser	account_id
0	desktop_web	Chrome	32
1	desktop_web	Safari	4

	device_type	user_browser	account_id
0	desktop_web	Safari	8

Все проблемные пользователи заходили десктопов и пользовались Хромом и Сафари.

Задача 3 (ошибочность ивентов)

1. Изучим пользователей, у которых есть только одно событие. Какой вид события встречается чаще всего? (Какие из встречающихся событий ошибочны?)
2. Изучим пользователей, у которых их два. (Какие из их последовательностей событий ошибочны?)

```

In [10]: ### Одно действие

# Группируем по пользователям и считаем количество событий
user_event_counts = df.groupby('account_id').size()
single_event_users = user_event_counts[user_event_counts == 1].index

# Фильтруем события этих пользователей
single_events = df[df['account_id'].isin(single_event_users)]

single_event_distribution = single_events['action_id'].value_counts()
print("1. ПОЛЬЗОВАТЕЛИ С ОДНИМ СОБЫТИЕМ:")
print(f"Всего пользователей с одним событием: {len(single_event_users)}")

```

```
print("Распределение событий:")
print(single_event_distribution)
```

1. ПОЛЬЗОВАТЕЛИ С ОДНИМ СОБЫТИЕМ:

Всего пользователей с одним событием: 7

Распределение событий:

```
action_id
playback_stop    3
click            2
playback_start   2
Name: count, dtype: int64
```

Опираясь на свои предположения, я бы сказал что ошибочными скорее всего являются либо включение плеера либо закрытие страницы просмотра, так как и то и то может произойти не намеренно. Более того, после ошибочного включения плеера может следовать намеренное закрытие страницы, что впринципе можно засчитать за ошибочное.

In [11]: *### Два действия*

```
two_event_users = user_event_counts[user_event_counts == 2].index
two_events = df[df['account_id'].isin(two_event_users)]

# Сортируем по времени для анализа последовательностей
two_events_sorted = two_events.sort_values(['account_id', 'server_time'])

# Создаем пары событий для каждого пользователя
two_events_pairs = two_events_sorted.groupby('account_id').agg({
    'action_id': list,
    'server_time': list
}).reset_index()

two_events_pairs['event_pair'] = two_events_pairs['action_id'].apply(lambda x: '
two_events_pairs['time_diff'] = two_events_pairs['server_time'].apply(lambda x:

print("2. ПОЛЬЗОВАТЕЛИ С ДВУМЯ СОБЫТИЯМИ:")
print(f"Всего пользователей с двумя событиями: {len(two_event_users)}")
print("Распределение пар событий:")
pair_distribution = two_events_pairs['event_pair'].value_counts()
print(pair_distribution)
```

2. ПОЛЬЗОВАТЕЛИ С ДВУМЯ СОБЫТИЯМИ:

Всего пользователей с двумя событиями: 7

Распределение пар событий:

```
event_pair
playback_start → playback_stop    3
playback_stop → playback_stop     1
playback_start → playback_pause   1
click → playback_pause             1
playback_start → click             1
Name: count, dtype: int64
```

Здесь скорее всего ошибочными были два выключения страницы подряд и так же включения проигрывателя, а за ним клик. Хотя возможно и клик по плееру, а за ним пауза - тоже ошибочно, так как смысла такие действия часто не несут со стороны пользователя.

Дальше переходим к анализу результатов нововведённой системы

```
In [12]: ### Установим необходимые для дальнейшего анализа библиотеки
import scipy.stats as sts
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
```

Следующий этап

Импортируем файл *Event_click.xlsx*.

В нем содержатся результаты A/B теста, который проводился в онлайн-кинотеатре.

В рамках эксперимента тестировалась новая рекомендательная система, цель которой - убедить пользователя просмотреть тот или иной тайтл.

Описание данных:

- *id_client* - уникальный идентификатор клиента
- *dttime_event* - дата совершения события (временная часть опущена для облегчения данных)
- *flag_group* - флаг принадлежности к тестовой группе (1 - тест, 0 - контроль).
- *event* - залогированное клиентское событие (play - пригрывание плеера, click - клик мышкой, scroll - прокручивание страницы)

Необходимо подготовить данные к анализу результатов A/B теста.

Для этого:

1. Определим нуллы в рамках каждого столбца (и их пересечений) и исключим все записи, в которых отсутствует информация хотя бы в одном поле.
2. Выявим клиентов, которые в течение эксперимента попадали в разные группы и исключим их из выборки.
3. Оценим общее количество исключений (относительно всей выборки).

```
In [13]: df = pd.read_excel("Event_click.xlsx")
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10554 entries, 0 to 10553
Data columns (total 4 columns):
#   Column          Non-Null Count  Dtype
---  -
0   id_client       10460 non-null   float64
1   dttime_event    10554 non-null   datetime64[ns]
2   flag_group      10162 non-null   float64
3   event           10041 non-null   object
dtypes: datetime64[ns](1), float64(2), object(1)
memory usage: 329.9+ KB
```

```
In [14]: # Анализ пропущенных значений по столбцам
null_counts = df.isnull().sum()
print("Количество пропусков по столбцам:")
for col, count in null_counts.items():
    print(f"{col}: {count} пропусков")
```

```
# Анализ пересечений пропущенных значений
print(f"\nОбщее количество записей с пропусками (хотя бы в одном поле): {df.isnu

# Исключаем ВСЕ записи с любыми пропусками
df_clean = df.dropna()
print(f"\nЗаписей после удаления ВСЕХ записей с пропусками: {df_clean.shape[0]}")
print(f"Удалено записей из-за пропусков: {df.shape[0] - df_clean.shape[0]}")
```

Количество пропусков по столбцам:

```
id_client: 94 пропусков
dttime_event: 0 пропусков
flag_group: 392 пропусков
event: 513 пропусков
```

Общее количество записей с пропусками (хотя бы в одном поле): 742

Записей после удаления ВСЕХ записей с пропусками: 9812

Удалено записей из-за пропусков: 742

Проверка показала, что пропуски распределены равномерно между тестовой и контрольной группами, а также не привязаны к конкретному целевому действию.

Следовательно, удаление этих строк безопасно и не создает системного перекоса в результатах эксперимента.

```
In [15]: # Рассчитываем количество уникальных значений flag_group для каждого клиента
client_group_counts = df_clean.groupby('id_client')['flag_group'].agg(['nunique',
client_group_counts.columns = ['unique_groups', 'total_records']

# Находим клиентов, которые были в разных группах
clients_in_multiple_groups = client_group_counts[client_group_counts['unique_gro

print(f"Клиентов в разных группах: {len(clients_in_multiple_groups)}")
if not clients_in_multiple_groups.empty:
    print("\nДетальная информация о клиентах в разных группах:")
    for client_id, row in clients_in_multiple_groups.iterrows():
        # Получаем все группы, в которых был клиент
        client_groups = df_clean[df_clean['id_client'] == client_id]['flag_group']
        print(f"Клиент {client_id}: был в группах {client_groups} ({row['total_r
```

Клиентов в разных группах: 10

Детальная информация о клиентах в разных группах:

```
Клиент 1008081.0: был в группах [0. 1.] (2 записей)
Клиент 1008096.0: был в группах [0. 1.] (2 записей)
Клиент 1008141.0: был в группах [0. 1.] (3 записей)
Клиент 1008153.0: был в группах [1. 0.] (3 записей)
Клиент 1012702.0: был в группах [1. 0.] (6 записей)
Клиент 1014274.0: был в группах [1. 0.] (6 записей)
Клиент 1014778.0: был в группах [1. 0.] (3 записей)
Клиент 1016908.0: был в группах [1. 0.] (5 записей)
Клиент 1018051.0: был в группах [1. 0.] (3 записей)
Клиент 1018067.0: был в группах [1. 0.] (3 записей)
```

```
In [16]: clients_to_exclude = clients_in_multiple_groups.index
df_final = df_clean[~df_clean['id_client'].isin(clients_to_exclude)]

print(f"\nЗаписей после исключения клиентов в разных группах: {df_final.shape[0]}
print(f"Удалено записей из-за клиентов в разных группах: {df_clean.shape[0] - df
print(f'Всего удалено записей для полной очистки: {df.shape[0] - df_final.shape[
```


Записей после исключения клиентов в разных группах: 9776

Удалено записей из-за клиентов в разных группах: 36

Всего удалено записей для полной очистки: 778

Задача новой рекомендательной системы заключается в том, чтобы повысить процент людей, которые при заходе на нашу страницу (то есть при совершении любого действия) перейдут в плеер (то есть совершат действие play).

Рассчитаем отдельно для *контрольной* и *тестовой* группы процент пользователей, которые совершили хотя бы одно действие play. Есть ли замечания по конверсии?

План действий:

- создадим столбец `flag_play`, принимающий значение 1, если совершаемое действие - 'play' и 0 для любого другого действия
- сгруппируем данные по двум столбцам одновременно - пользователь и его группа - и посчитаем максимальное значение по колонке `flag_play` (если пользователь хотя бы раз играл, то максимальное значение будет 1, если ни разу, то 0)
- возьмем среднее значение полученного `max_flag` для тестовой и контрольной групп - отличаются ли значения?
- проведем t-тест по колонке `max_flag` для тестовой и контрольной групп, чтобы оценить стат. значимость разницы в средних значениях между ними.

```
In [17]: # 1. Создаем колонку flag_play
df_final['flag_play'] = (df_final['event'] == 'play').astype(int)
print("Добавлена колонка flag_play (1 = play, 0 = другие действия)")

# 2. Группируем по пользователю и группе, считаем максимальное значение flag_pla
user_conversion = df_final.groupby(['id_client', 'flag_group'])['flag_play'].max
user_conversion.rename(columns={'flag_play': 'max_flag'}, inplace=True)

print(f"\nУникальных пользователей в анализе: {user_conversion['id_client'].nuni

# 3. Рассчитываем средние значения для тестовой и контрольной групп
conversion_rates = user_conversion.groupby('flag_group')['max_flag'].agg(['mean']
conversion_rates['conversion_rate'] = conversion_rates['mean'] * 100

print("\nКонверсия в просмотр по группам:")
print(conversion_rates[['count', 'conversion_rate']])

# Детальная информация по группам
control_group = user_conversion[user_conversion['flag_group'] == 0]
test_group = user_conversion[user_conversion['flag_group'] == 1]

print(f"\nКонтрольная группа (0):")
print(f"- Пользователей: {len(control_group)}")
print(f"- Конверсия в play: {control_group['max_flag'].mean()} ({control_group['
print(f"- Пользователей с play: {control_group['max_flag'].sum()}")
print(f"- Пользователей без play: {len(control_group) - control_group['max_flag'

print(f"\nТестовая группа (1):")
print(f"- Пользователей: {len(test_group)}")
```

```
print(f"- Конверсия в play: {test_group['max_flag'].mean()} ({test_group['max_flag'].sum()/len(test_group)})")
print(f"- Пользователей с play: {test_group['max_flag'].sum()}")
print(f"- Пользователей без play: {len(test_group) - test_group['max_flag'].sum()}")
```

Добавлена колонка flag_play (1 = play, 0 = другие действия)

Уникальных пользователей в анализе: 6004

Конверсия в просмотр по группам:

	count	conversion_rate
0	3014	28.334439
1	2990	31.471572

Контрольная группа (0):

- Пользователей: 3014
- Конверсия в play: 0.2833443928334439 (28.33443928334439%)
- Пользователей с play: 854
- Пользователей без play: 2160

Тестовая группа (1):

- Пользователей: 2990
- Конверсия в play: 0.3147157190635452 (31.471571906354516%)
- Пользователей с play: 941
- Пользователей без play: 2049

Так как выборка большая (около 6 000 пользователей), t-тест работает отлично благодаря ЦПТ.

```
In [18]: # 4. Проводим t-тест для оценки статистической значимости
t_stat, p_value = sts.ttest_ind(control_group['max_flag'], test_group['max_flag'])
print(f"t-статистика: {t_stat}")
print(f"p-value: {p_value}")

print(f"\nИнтерпретация:")
if p_value < 0.05:
    print("✅ Разница в конверсии СТАТИСТИЧЕСКИ ЗНАЧИМА (p < 0.05)")
    if test_group['max_flag'].mean() > control_group['max_flag'].mean():
        print("✅ Новая рекомендательная система УЛУЧШИЛА конверсию")
    else:
        print("❌ Новая рекомендательная система УХУДШИЛА конверсию")
else:
    print("❌ Разница в конверсии НЕ СТАТИСТИЧЕСКИ ЗНАЧИМА (p ≥ 0.05)")
    print("❌ Нет доказательств влияния новой системы на конверсию")
```

t-статистика: -2.655959605685953

p-value: 0.007929215584901563

Интерпретация:

- ✅ Разница в конверсии СТАТИСТИЧЕСКИ ЗНАЧИМА (p < 0.05)
- ✅ Новая рекомендательная система УЛУЧШИЛА конверсию

Допустим, активностью пользователя является любая активность (совершение любого действия, хотя бы одного):

1. Рассчитаем и визуализируем DAU (по оси X - дни), и так же WAU (по оси X - недели) (исключим неполные недели).
2. Соединим DAU и WAU и визуализируем их на одном графике.

Какие выводы можно сделать на основании имеющихся данных?

```
In [19]: df_final['date'] = df_final['datetime_event'].dt.date

dau = df_final.groupby('date')['id_client'].nunique().reset_index()
dau.columns = ['date', 'dau']
dau['day_of_week'] = pd.to_datetime(dau['date']).dt.day_name()

print("DAU по дням:")
print(dau)
```

DAU по дням:

	date	dau	day_of_week
0	2024-01-01	390	Monday
1	2024-01-02	391	Tuesday
2	2024-01-03	400	Wednesday
3	2024-01-04	399	Thursday
4	2024-01-05	415	Friday
5	2024-01-06	435	Saturday
6	2024-01-07	390	Sunday
7	2024-01-08	212	Monday
8	2024-01-09	198	Tuesday
9	2024-01-10	220	Wednesday
10	2024-01-11	215	Thursday
11	2024-01-12	212	Friday
12	2024-01-13	372	Saturday
13	2024-01-14	446	Sunday
14	2024-01-15	207	Monday
15	2024-01-16	204	Tuesday
16	2024-01-17	198	Wednesday
17	2024-01-18	200	Thursday
18	2024-01-19	212	Friday
19	2024-01-20	520	Saturday
20	2024-01-21	530	Sunday
21	2024-01-22	218	Monday
22	2024-01-23	200	Tuesday
23	2024-01-24	203	Wednesday
24	2024-01-25	200	Thursday
25	2024-01-26	210	Friday
26	2024-01-27	583	Saturday
27	2024-01-28	594	Sunday
28	2024-01-29	210	Monday
29	2024-01-30	194	Tuesday
30	2024-01-31	179	Wednesday

```
In [20]: df_final['date'] = df_final['datetime_event'].dt.date

print("\nПериод данных:", df_final['date'].min(), "-", df_final['date'].max())

# ПАЧЕТ DAU (Daily Active Users)
print("\n" + "="*50)
print("ПАЧЕТ DAU")
print("="*50)

dau = df_final.groupby('date')['id_client'].nunique().reset_index()
dau.columns = ['date', 'dau']
dau['datetime'] = pd.to_datetime(dau['date'])
dau['day_of_week'] = dau['datetime'].dt.day_name()

print("DAU по дням:")
print(dau[['date', 'dau']])
```

```

# PACЧЕТ WAU (Weekly Active Users)
print("\n" + "="*50)
print("PACЧЕТ WAU")
print("="*50)

# Добавляем информацию о неделе и годе
df_final['year'] = df_final['datetime_event'].dt.isocalendar().year
df_final['week'] = df_final['datetime_event'].dt.isocalendar().week

# Исключаем неполные недели (проверяем количество дней в неделе)
week_days_count = df_final.groupby(['year', 'week'])['date'].nunique()
full_weeks = week_days_count[week_days_count == 7].index

print(f"Полные недели: {len(full_weeks)}")
print("Недели с полными данными:", [f"{w}-{y}" for y, w in full_weeks])

# Фильтруем только полные недели
df_full_weeks = df_final[df_final[['year', 'week']].apply(tuple, axis=1).isin(full_weeks)]

# Рассчитываем WAU
wau = df_full_weeks.groupby(['year', 'week'])['id_client'].nunique().reset_index
wau.columns = ['year', 'week', 'wau']

# Добавляем первую дату каждой недели для визуализации
wau['first_date'] = wau.apply(lambda x:
    df_full_weeks[(df_full_weeks['year'] == x['year']) &
        (df_full_weeks['week'] == x['week'])]['date'].min(), axis=1)

print("\nWAU по полным неделям:")
print(wau[['year', 'week', 'wau', 'first_date']])

```

Период данных: 2024-01-01 - 2024-01-31

=====
РАСЧЕТ DAU

=====
DAU по дням:

	date	dau
0	2024-01-01	390
1	2024-01-02	391
2	2024-01-03	400
3	2024-01-04	399
4	2024-01-05	415
5	2024-01-06	435
6	2024-01-07	390
7	2024-01-08	212
8	2024-01-09	198
9	2024-01-10	220
10	2024-01-11	215
11	2024-01-12	212
12	2024-01-13	372
13	2024-01-14	446
14	2024-01-15	207
15	2024-01-16	204
16	2024-01-17	198
17	2024-01-18	200
18	2024-01-19	212
19	2024-01-20	520
20	2024-01-21	530
21	2024-01-22	218
22	2024-01-23	200
23	2024-01-24	203
24	2024-01-25	200
25	2024-01-26	210
26	2024-01-27	583
27	2024-01-28	594
28	2024-01-29	210
29	2024-01-30	194
30	2024-01-31	179

=====
РАСЧЕТ WAU

=====
Полные недели: 4

Недели с полными данными: ['1-2024', '2-2024', '3-2024', '4-2024']

WAU по полным неделям:

	year	week	wau	first_date
0	2024	1	2458	2024-01-01
1	2024	2	1712	2024-01-08
2	2024	3	1874	2024-01-15
3	2024	4	2002	2024-01-22

```
In [21]: # ВИЗУАЛИЗАЦИЯ DAU И WAU НА ОДНОМ ГРАФИКЕ
print("\n" + "="*50)
print("СОВМЕСТНАЯ ВИЗУАЛИЗАЦИЯ DAU И WAU")
print("="*50)

plt.figure(figsize=(15, 8))


# Визуализация DAU
```

```
plt.plot(dau['datetime'], dau['dau'], marker='o', linewidth=2,
         markersize=4, color='blue', alpha=0.7, label='DAU')

# Визуализация WAU - создаем точки для каждого дня недели
for _, row in wau.iterrows():
    week_dates = df_full_weeks[(df_full_weeks['year'] == row['year']) &
                                (df_full_weeks['week'] == row['week'])]['date'].unique()
    week_dates.sort()

    # Рисуем горизонтальную линию для WAU через все дни недели
    plt.plot(week_dates, [row['wau']] * len(week_dates),
             linewidth=3, color='green', alpha=0.7, label='WAU' if _ == 0 else "")

plt.title('Сравнение DAU и WAU', fontsize=16, fontweight='bold')
plt.xlabel('Дата')
plt.ylabel('Количество пользователей')
plt.legend()
plt.grid(True, alpha=0.3)
plt.xticks(rotation=45)
plt.tight_layout()
plt.show()
```



```
In [22]: fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(15, 10))

# График DAU
ax1.plot(dau['datetime'], dau['dau'], marker='o', linewidth=2, markersize=4, color='blue', alpha=0.7)
ax1.set_title('DAU (Daily Active Users)', fontsize=14, fontweight='bold')
ax1.set_ylabel('Количество пользователей')
ax1.grid(True, alpha=0.3)
ax1.tick_params(axis='x', rotation=45)


# График WAU (столбчатая диаграмма)
wauBars = ax2.bar(range(len(wau)), wau['wau'], color='green', alpha=0.7)
ax2.set_title('WAU (Weekly Active Users)', fontsize=14, fontweight='bold')
ax2.set_xlabel('Неделя')
ax2.set_ylabel('Количество пользователей')
ax2.set_xticks(range(len(wau)))
ax2.set_xticklabels([f"Неделя {w}\n({pd.to_datetime(d).strftime('%d.%m')})" for w, d in enumerate(wau.index)])
```

```

for w, d in zip(wau['week'], wau['first_date'])), rotation=4
ax2.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

```



```

In [23]: # АНАЛИЗ И ВЫВОДЫ
print("\n" + "="*50)
print("АНАЛИЗ И ВЫВОДЫ")
print("="*50)

print("Ключевые метрики:")
print(f"Средний DAU: {dau['dau'].mean():.1f} пользователей в день")
print(f"Медианный DAU: {dau['dau'].median():.1f} пользователей в день")
print(f"Минимальный DAU: {dau['dau'].min()} пользователей")
print(f"Максимальный DAU: {dau['dau'].max()} пользователей")
print(f"Стандартное отклонение DAU: {dau['dau'].std():.1f}")

print(f"\nСредний WAU: {wau['wau'].mean():.1f} пользователей в неделю")
print(f"Медианный WAU: {wau['wau'].median():.1f} пользователей в неделю")

```

```

=====
АНАЛИЗ И ВЫВОДЫ
=====

Ключевые метрики:
Средний DAU: 308.3 пользователей в день
Медианный DAU: 215.0 пользователей в день
Минимальный DAU: 179 пользователей
Максимальный DAU: 594 пользователей
Стандартное отклонение DAU: 133.1

Средний WAU: 2011.5 пользователей в неделю
Медианный WAU: 1938.0 пользователей в неделю

```

Изменятся ли выводы, если поменять определение "активности"?

Допустим, только действие *play* будет считаться за активность, а не любые действия

вообще.

```
In [24]: df_play_only = df_final[df_final['event'] == 'play'].copy()
print(f"Записей с событием play: {len(df_play_only)}")
print(f"Уникальных пользователей с play: {df_play_only['id_client'].nunique()}")

# РАСЧЕТ DAU (ТОЛЬКО PLAY)
print("\n" + "="*50)
print("РАСЧЕТ DAU (ТОЛЬКО PLAY)")
print("="*50)

dau_play = df_play_only.groupby('date')['id_client'].nunique().reset_index()
dau_play.columns = ['date', 'dau_play']
dau_play['datetime'] = pd.to_datetime(dau_play['date'])

print("DAU (только play) по дням:")
print(dau_play[['date', 'dau_play']])

# РАСЧЕТ WAU (ТОЛЬКО PLAY)
print("\n" + "="*50)
print("РАСЧЕТ WAU (ТОЛЬКО PLAY)")
print("="*50)

# Добавляем информацию о неделе
df_play_only['year'] = df_play_only['datetime'].dt.isocalendar().year
df_play_only['week'] = df_play_only['datetime'].dt.isocalendar().week

# Исключаем неполные недели
week_days_count = df_play_only.groupby(['year', 'week'])['date'].nunique()
full_weeks = week_days_count[week_days_count == 7].index

print(f"Полные недели с play: {len(full_weeks)}")

# Фильтруем только полные недели
df_play_full_weeks = df_play_only[df_play_only[['year', 'week']].apply(tuple, axis=1).isin(full_weeks)]

# Рассчитываем WAU
wau_play = df_play_full_weeks.groupby(['year', 'week'])['id_client'].nunique().reset_index()
wau_play.columns = ['year', 'week', 'wau_play']

print("\nWAU (только play) по полным неделям:")
print(wau_play[['year', 'week', 'wau_play']])
```


Записей с событием play: 2035
Уникальных пользователей с play: 1795

=====

РАСЧЕТ DAU (ТОЛЬКО PLAY)

=====

DAU (только play) по дням:

	date	dau_play
0	2024-01-01	82
1	2024-01-02	81
2	2024-01-03	87
3	2024-01-04	85
4	2024-01-05	81
5	2024-01-06	92
6	2024-01-07	91
7	2024-01-08	51
8	2024-01-09	41
9	2024-01-10	47
10	2024-01-11	41
11	2024-01-12	47
12	2024-01-13	75
13	2024-01-14	89
14	2024-01-15	44
15	2024-01-16	41
16	2024-01-17	45
17	2024-01-18	33
18	2024-01-19	49
19	2024-01-20	107
20	2024-01-21	116
21	2024-01-22	48
22	2024-01-23	39
23	2024-01-24	40
24	2024-01-25	39
25	2024-01-26	40
26	2024-01-27	127
27	2024-01-28	144
28	2024-01-29	43
29	2024-01-30	42
30	2024-01-31	37

=====

РАСЧЕТ WAU (ТОЛЬКО PLAY)

=====

Полные недели с play: 4

WAU (только play) по полным неделям:


	year	week	wau_play
0	2024	1	582
1	2024	2	383
2	2024	3	423
3	2024	4	464

```
In [25]: fig, (ax1, ax2) = plt.subplots(2, 1, figsize=(15, 10))

# График DAU
ax1.plot(dau_play['datetime'], dau_play['dau_play'], marker='o', linewidth=2, ma
ax1.set_title('DAU (Daily Active Users)', fontsize=14, fontweight='bold')
ax1.set_ylabel('Количество пользователей')
ax1.grid(True, alpha=0.3)
ax1.tick_params(axis='x', rotation=45)
```

```
# График WAU (столбчатая диаграмма)
wau_play = ax2.bar(range(len(wau)), wau_play['wau_play'], color='green', alpha=0.3)
ax2.set_title('WAU (Weekly Active Users)', fontsize=14, fontweight='bold')
ax2.set_xlabel('Неделя')
ax2.set_ylabel('Количество пользователей')
ax2.set_xticks(range(len(wau)))
ax2.set_xticklabels([f"Неделя {w}\n({pd.to_datetime(d).strftime('%d.%m')})"
                     for w, d in zip(wau['week'], wau['first_date'])], rotation=45)
ax2.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()
```



Несмотря на изменение условий активности - сама *динамика* показателей WAU/DAU осталась приблизительно той же.

Это, в свою очередь, может привести к тому, что действие *play* как раз и задает основную траекторию динамики активности юзеров, отображая реальный уровень вовлеченности клиентов, и что прочие действия, совершаемые нашими клиентами, скорее "вторят" этой динамике. Это совершенно нормально, даже ожидаемо, тем самым положительно отзываясь об состоянии платформы в целом.

In []: